


Modellbasierter Entwurf

Neuronale Netze



BEUTH HOCHSCHULE FÜR TECHNIK BERLIN

University of Applied Sciences

Fachbereich VI

Technische Informatik

Teilnehmer	Matrikelnummer
Bryan Scheffner	888777
Toni Reichel	897991

Inhaltsverzeichnis

1	Einleitung	3
1.1	Aufgabenstellung	3
1.2	Motivation neuronaler Netze	3
1.3	Das menschliche Nervensystem	4
1.4	Neuronale Netze und ihre Bedeutung - [2, S. 12]	7
2	Aufbau des neuronalen Netzes	9
3	Erzeugung der Eingangsbilder	12
4	Gewichtsmatrizen	17
4.1	Erzeugung der Gewichtsmatrizen	18
4.2	Additive Überlagerung	21
4.3	Multiplikative Überlagerung Typ 1	22
4.4	Multiplikative Überlagerung Typ 2	23
4.5	Additive und Multiplikative Überlagerung	24
4.6	Spezielle Überlagerung	25
5	Das Matlab Tool	26
5.1	Modulübersicht	26
5.2	Erläuterung der Parameter	28
6	Auswertung	29
6.1	AddMul Gewichtsmatrix	30
6.1.1	H-Balken	30
6.1.2	V-Balken	34
6.1.3	Kreuz	38
6.2	Special Gewichtsmatrix	42
6.2.1	H-Balken	42
6.2.2	V-Balken	46
6.2.3	Kreuz	50
7	Fazit	54

1 Einleitung

1.1 Aufgabenstellung

In dieser Arbeit soll ein einfaches neuronales Netz aufgebaut werden, welches horizontale und vertikale Balken erkennen kann. Dafür werden die zentralen Themen sein, eine geeignete Gewichtsmatrix und den Aufbau des Netzes zu finden. Bevor eine Hardwareimplementierung stattfindet sollen Simulationen durchgeführt werden, die die Funktion des neuronalen Netzes absichern. Darüber hinaus bietet die Simulation uns die Möglichkeit, eine optimale Konfiguration zu finden. Das Ziel dieser Arbeit ist es, das Prinzip hinter neuronalen Netzen besser zu verstehen und nicht bereits erforschte Netztopologie zu übernehmen. Für diese Arbeit sind wir wie folgt vorgegangen:

1. Allgemeine Informationssammlung zu neuronalen Netzen
2. Grundüberlegung der Gewichtung der einzelnen Pixel
3. Aufbau des Netzes
4. Auswertung der verschiedenen gefundenen Möglichkeiten

Alle Ergebnisse dieser Arbeit können mit dem von uns geschriebenen Matlab-Skripten nachvollzogen werden. Mithilfe dieser Skripte haben wir viele Simulationen durchgeführt und Erkenntnisse für das bessere Verständnis neuronaler Netze gewonnen.

1.2 Motivation neuronaler Netze

Heutzutage findet man in nahezu allen Bereichen des Lebens Programme vor, sei es in Zahnbürsten, Autos oder in Robotern am Fließband. Mithilfe von Programmen sollen also sich wiederholende Aufgaben vereinfacht oder automatisiert werden. Dafür werden die Programme mit prozedurale oder objektorientierte Methoden entwickelt. Bevor mit der Programmierung angefangen werden kann, muss zuerst ein Modell des Problems entworfen werden. Bei einfachen Anwendungen, wie zum Beispiel einer Zahnbürste ist es recht einfach. Möchte man allerdings ein Modell für eine Mustererkennung realisieren, stößt man mit herkömmlichen Methoden der Programmierung schnell an die Grenzen des machbaren. An dieser Stelle kommen neuronale Netze ins Spiel, die die Vorteile des menschlichen Denkens und Verhaltens emulieren sollen. Denn das menschliche Denken und Verhalten unterscheidet sich sehr stark von dem einer Maschine. Eine Maschine kann in der Regel nicht kreativ sein, Lösungen interpolieren, aus Fehlern lernen und phantasievoll sein.

Bei der klassischen Programmierung spricht man auch von einer symbolischen Informationsverarbeitung. Alle Schritte sind dem Programmierer bewusst und er kann genau sagen, wie sich sein Programm verhalten wird. Vorausgesetzt er hat vorab ein präzises Modell erarbeitet. Dem Gegenüber steht die Programmierung mit neuronalen Netzen. Bei neuronalen Netzen spricht man von einer sub-symbolischen Informationsverarbeitung. Der Programmierer des neuronalen Netzwerkes kann trotz eines genauen Modells nicht 100% sicher sagen, wie sich das neuronale Netzwerk am Anfang verhalten wird. Erst wenn das neuronale Netzwerk konfiguriert wurde, ist es möglich genaueres Verhalten des neuronalen Netzes abzuschätzen. Die sub-symbolische Programmierung ist immer dann einzusetzen, wenn es schwer möglich ist die 'Realwelt' perfekt als Modell abzubilden.

Die Grundidee der sub-symbolischen Informationsverarbeitung ist das Auflösen der Symbole zur Beschreibung der Anwendungswelt in Mikrostrukturen auf der Basis primitiver Verarbeitungseinheiten (simulierter Neuronen). [2, S. 9]

Um besser zu verstehen, wie Nervenzellen (Neuronen) funktionieren, handelt der nächste Abschnitt über das menschliche Nervensystem.

1.3 Das menschliche Nervensystem

Das menschliche Gehirn besteht aus etwa 86 Milliarden Nervenzellen, auch Neuronen genannt, die zum Zentralnervensystem miteinander verschaltet sind (im folgendem Nervensystem).[1] Nervenzellen im Gehirn sind hochspezialisierte Zellen, die sich im Gegensatz zu einfacheren Zellen nicht teilbar sind. Das bedeutet, dass sich das Nervensystem nicht über Zellteilung regenerieren kann. Allerdings schafft es das Gehirn durch die Verknüpfung anderer Nervenzellen den Defekt teilweise oder komplett auszugleichen. Jede Nervenzelle kann mit bis zu 10.000 anderen Nervenzellen in Verbindung stehen.[4]

Jede Nervenzelle ist im Grundaufbau gleich, kann aber unterschiedliche Formen und Größen haben. Das liegt unter anderem daran, dass sich Nervenzellen weiter spezialisieren.[4] So können die einen Nervenzellen für motorische und die anderen für sensorische Aufgaben bestimmt sein. Dadurch erreichen Nervenzellen unterschiedliche Geschwindigkeiten, wie sie Informationen an andere Nervenzellen weitergeben.[1] Der Informationsfluss ist dabei immer in die gleiche Richtung.[4] In Abbildung 1 ist der Aufbau einer Nervenzelle dargestellt.

Der hier stark vereinfachte Aufbau einer Nervenzelle besteht aus dem Zellkörper, den Dendriten, dem Axon und den Synapsen. Die Synapsen liegen jeweils am Ende der Dendriten und des Axons. Der Zellkörper bildet die zentrale Einheit einer Nervenzelle und erhält seine Informationen über die Dendriten. Die Dendriten sind baumartig verzweigt und mit anderen Nervenzellen




Abbildung 1: Aufbau Neuron [3, S. 11]

über Synapsen verbunden. Der Zellkörper bildet eine Summation über die Signale der vielen verschiedenen Dendriten. Dabei kann jedes Dendrit eine erregende oder hemmende Wirkung auf den Zellkörper haben. Bei ausreichender Stärke leitet der Zellkörper das Signal weiter. Wenn eine Erregungsweiterleitung stattfindet, wird das Signal über das Axon und Synapsen an die nächste Nervenzelle weitergeleitet. Ein Axon hat einen Durchmesser von 0,002 - 0,01 Millimetern und kann bis zu einem Meter lang sein.[4] Umso dicker ein Axon ist, desto schneller findet auch die Weiterleitung statt. Jede Nervenzelle kann nur über ihre Synapsen mit anderen Nervenzellen kommunizieren. Dafür hat jede Nervenzelle bis zu 10.000, in manchen Extremfälle sogar mehr als 100.000 Synapsen.[1] Synapsen kommunizieren untereinander mit chemischen oder elektrischen Signalen. Wobei elektrische in chemische und chemische in elektrische Signale umgewandelt werden. In der Regel kommunizieren Synapsen über chemische Signale. Der Grund dafür ist, dass Synapsen meisten keinen direkten Kontakt zueinander haben, sondern ein kleiner Abstand von 20 bis 50 Nanometern bleibt.[1] Bei elektrischen Synapsen ist der Abstand so nah, dass über eine kleine Brücke (gap junction) kommuniziert wird. Dabei kann das Signal schneller weitergeleitet werden.[4]

Das Nervensystem ist ein großes Netz aus sehr vielen Nervenzellen, die unterschiedlich stark miteinander verbunden sind und unterschiedlich schnell Signale weiterleiten. Wenn eine Nervenzelle ein Signal auslöst, weil eine gewisse Schwelle überschritten wurde spricht man auch

davon, dass das Aktionspotenzial erreicht wurde. Das Aktionspotenzial kann nur erreicht werden, wenn vorher genügend vorgeschaltete Nervenzellen ein Signal gesendet haben. Der Anfang einer Verkettung von Nervenzellen kann zum Beispiel über sehen, schmecken, spüren oder ähnliches stattfinden. Wird ein Aktionspotenzial in den dafür verantwortlichen Nervenzellen erreicht, werden sie wieder Signale an andere Nervenzellen senden. Am Ende kann das Signal bei Nervenzellen ankommen, die für eine Bewegung verantwortlich sind, wie zum Beispiel eine Gehbewegung. Das ist ein sehr stark vereinfachtes Beispiel und soll nur dazu dienen die Mechanismen eines Nervensystems zu verstehen.

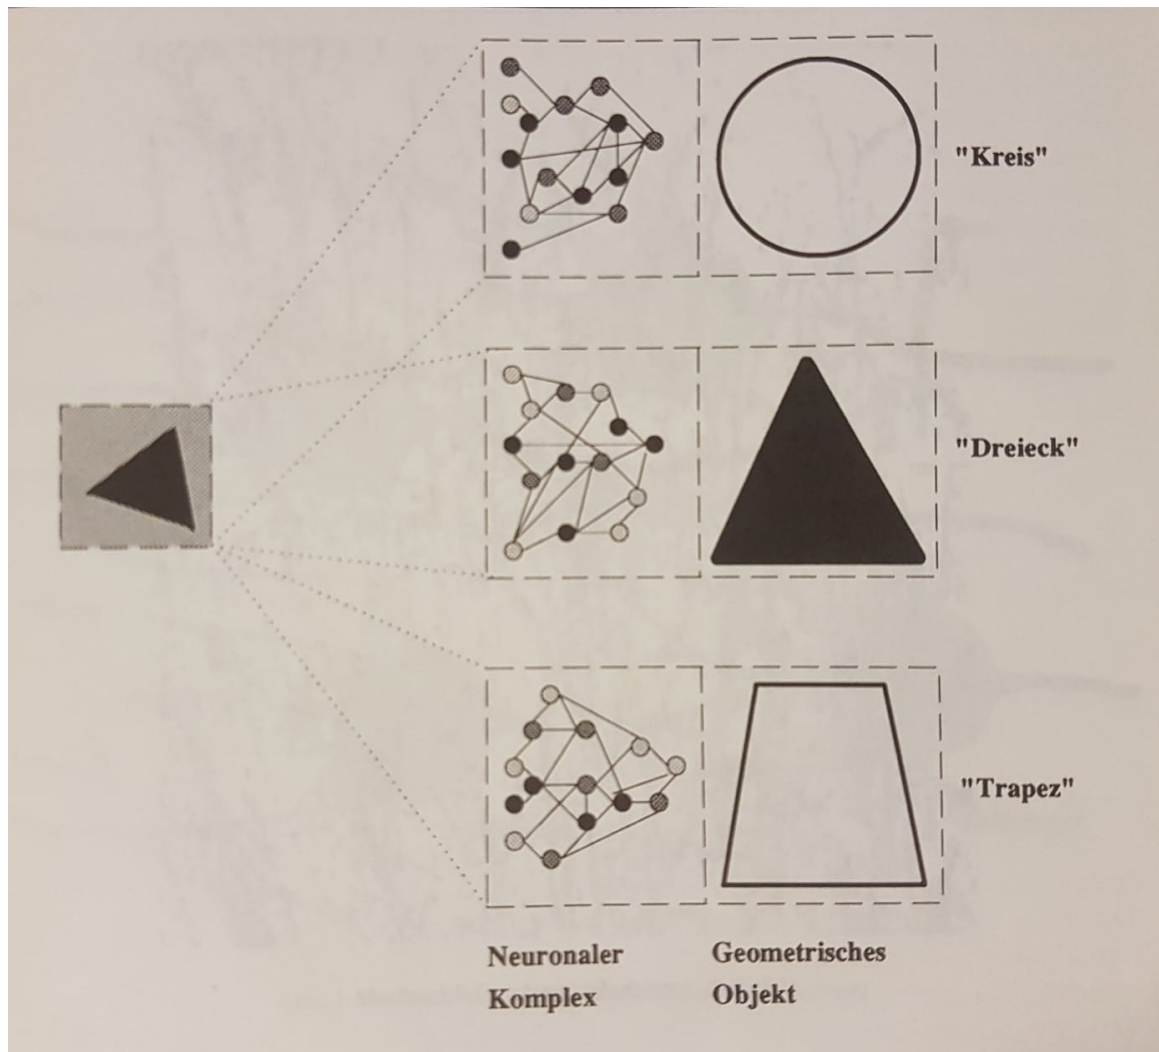


Abbildung 2: Verarbeitung eines visuellen Eindrucks [2, S. 9]

In Abbildung 2 ist zu sehen, wie ein visueller Eindruck in einem neuronalen Netzwerk verarbeitet wird. Im neuronale Netzwerk werden bei verschiedenen visuellen Eindrücken verschiedene Neuronen unterschiedlich stark stimuliert. Umso mehr sich Objekte voneinander unterscheiden, desto mehr wird sich auch das neuronale Netzwerk in der Stimulation der einzelnen Neuronen unterscheiden. Dabei gibt es nicht nur zwei Stufen der Unterscheidung, sondern mehrere. Kennt man die Stimulationen der einzelnen Neuronen auf verschiedene geometrische Referenz-Objekte,

wie eines 'Kreis', 'Dreieck' oder 'Trapez' kann man neue unbekannte geometrische Objekte mit bekannten vergleichen und eine Aussage darüber treffen, um was es sich für ein Objekt handelt. Die Entscheidung ist dabei mit Wahrscheinlichkeiten verbunden. Ist die Übereinstimmung mit einem Referenz-Objekt sehr hoch, wird es auch möglich sein eine gute Aussagekraft über das unbekannte Objekt zu erhalten. Umso mehr sich ein unbekanntes Objekt von den Referenz-Objekten unterscheidet, desto geringer wird auch die Aussagekraft über das unbekannte Objekt sein.

1.4 Neuronale Netze und ihre Bedeutung - [2]

Um besser zu verstehen, wie das menschliche Gehirn funktioniert wurden von Biologen, Neurophysiologen und Kognitionswissenschaftler neuronale Verarbeitungsmodelle entwickelt. Bei den entwickelten Verarbeitungsmodelle ist darauf zu achten, dass sie sehr stark vereinfacht sind. Sie sollen viel mehr genutzt werden, um Theorien zu untermauern. Die Verarbeitungsmodelle umfassen eine Vielzahl von Annahmen der menschlichen Gehirnstruktur, die nicht eindeutig belegt sind.

Neuronale Netzwerke sind Modelle der Gehirnfunktion. Sie versuchen, in Struktur und Funktionsweise Gehirnzellkomplexe nachzubilden und dadurch eine tragfähige Simulation komplexer menschlicher Denkvorgänge zu erzielen. [2, S. 12]

Am menschlichen Gehirn sind nicht nur die kreativen und phantasievollen Fähigkeiten erstaunlich. Auch die Fähigkeit etwas neues zu lernen und neue Lösungen für Probleme zu finden. Wenn Teile des menschlichen Gehirns beschädigt werden, wie zum Beispiel durch einen Schlaganfall, schafft es das menschliche Gehirn die auftretenden neurologischen Ausfälle teilweise bzw. komplett zu regenerieren. All diese Vorteile können nicht mit einem herkömmlichen Programm nachgebildet werden und es bedarf die Implementierung eines künstlichen neuronalen Netzwerks. Dabei müssen nicht alle Facetten des menschlichen Gehirns nachgebildet werden, sondern nur grundlegende Funktionen.

Ein Vorteil, die ein künstliches neuronales Netz übernehmen kann von einem menschlichen Gehirn sind unter anderem die Robustheit. Wenn bei einem hinreichend großem Netz ein Neuron ausfällt, dann können umliegende Neuronen die Aufgabe übernehmen, wenn man das neuronale Netzwerk neu anlernen würde. Aber auch bei nicht neu anlernen des Netzwerkes würde zwar die Qualität der Aussage schlechter werden, aber es könnten immer noch Aussagen getroffen werden. Dies gilt bei Aufgabenstellungen, die assoziierenden, interpolierenden, klassifizierenden oder beurteilenden Charakter haben.

Ein zweiter Vorteil von künstlichen neuronalen Netzen in der modernen Mehrprozessor-Rechner-Architektur sind die Modellinhärenten Parallelisierungsmöglichkeiten. So können Neuronen zu bestimmten Gruppen zusammengefasst werden, ähnlich wie es auch im menschlichen Nervensystem realisiert wird, und sehr stark miteinander vernetzt sein. Jede Gruppe wird dann auf verschiedenen Prozessoren ausgeführt und nur notwendige Verbindungen über die Prozessoren hinaus verbunden. Das gilt natürlich nicht nur für Software-, sondern auch für Hardwareimplementierungen.

Ein dritter Vorteil von künstlichen neuronalen Netzen ist die Adaptivität, also die Fähigkeit etwas zu erlernen. Dafür gibt es für fast jedes Netzmodell Verfahren, die es dem Netzwerk erlauben sich selbst zu konfigurieren. Soll ein neuronales Netzwerk Muster erkennen, dann werden dem neuronalen Netzwerk vorab Beispiele für zu erkennende Muster gegeben und damit das Netzwerk konfiguriert. Man spricht davon auch von Trainingsbeispielen. Diese Trainingsbeispiele sollten möglichst reproduzierbar sein. Am Ende des Trainings soll das neuronale Netzwerk bisher unbekannte Muster durch Assoziation bzw. Interpolations erkennen.

Trotz dieser ganzen Vorteile künstlicher neuronaler Netze ist es nicht möglich zukünftig ohne die klassische Programmierung auszukommen. Für jede neue Anwendung muss immer eine Ein- und Ausgabecodierung vorliegen. Wie soll der Anwender am Ende sonst erkennen, wie das Ergebnis zu interpretieren ist. Bei den Ein- und Ausgaben handelt es sich um teils komplexe Transformationen. Neuronale Netzwerke bieten einen großen Einsatzbereich, sind aber nicht in der Lage die herkömmliche Programmierung komplett zu ersetzen. Es kommt vielmehr auf das Einsatzgebiet an, wo man mehr mit neuronalen Netzwerken, mit herkömmlichen Programmiermethodiken oder mit einer Kombination arbeitet.

2 Aufbau des neuronalen Netzes

In diesem Abschnitt wird erklärt, wie unser neuronales Netz aufgebaut ist. Vor allem die Abbildung 3 ist für das bessere Verständnis der Matlab-Skripte wichtig. In den Matlab-Skripten muss immer die Pixelanzahl und die Merkmalanzahl angegeben werden. Dabei handelt es sich immer um einen symmetrischen Aufbau. Ist die Merkmalanzahl gleich 5, dann gibt es 25 Merkmale (5 in x-Richtung und 5 in y-Richtung). Das gleiche gilt für die Pixelanzahl. Bei einer Pixelanzahl von 8 werden für jedes Merkmale 8 mal 8 Pixel angenommen. Bei einer Merkmalanzahl von 5 und einer Pixelanzahl von 8 wird also eine Pixelmatrix von 40 mal 40 Pixel erzeugt.




Abbildung 3: Anordnung der Merkmale und Pixel

In Abbildung 4 ist ein Neuronenbeispiel abgebildet. Dieses Neuron der 1. Ebene fasst ein komplettes Merkmal mit all seinen Pixel zusammen. Dieses Neuron hat also in unserem Beispiel 64 Eingänge und es gibt 25 solcher Neuronen.




Abbildung 4: Neuron der 1. Ebene

Mit einer einzigen Ebene von Neuronen kann sehr viel erreicht werden. Allerdings ist für die Gesamtauswertung ein zweites von Vorteil, um zum Beispiel besser Fehler zu detektieren bei sehr viel Rauschen. Bevor wir uns die zweite Ebene der Neuronen angucken, werfen wir einen Blick auf die Abbildung 5. Hier sind drei Arten von Merkmalen zu erkennen. Die fünf schwarzen Merkmale detektieren einen horizontalen Balken, die blauen Merkmale einen vertikalen Balken und die roten Merkmale können hohes Rauschen detektieren. Die roten Merkmale erlauben es, eine bessere Konfiguration des neuronalen Netzes zu finden.




Abbildung 5: Erläuterung der Anordnung für die 2. Ebene

In Abbildung 6 ist die komplette zweite Ebene des Neuronalen Netzes dargestellt. Alle drei Merkmale-Typen werden jeweils auf ein Neuron gegeben. In diesem Fall sind alle Gewichte auf eins gesetzt. Es muss nur der Bias eingestellt und eine Schwelle zur Detektion festgelegt werden.

Für die Auswertung der Neuronen der ersten Ebene nutzen wir eine Sigmoid-Funktion. Für die zweite Ebene werden allerdings nicht die Ergebnisse der Sigmoid-Funktion weitergegeben, sondern die addierten Werte werden ohne eine weitere Verarbeitung an die zweite Ebene weitergegeben. Das entspricht einer linearen Aktivierungsfunktion mit dem Anstieg eins.

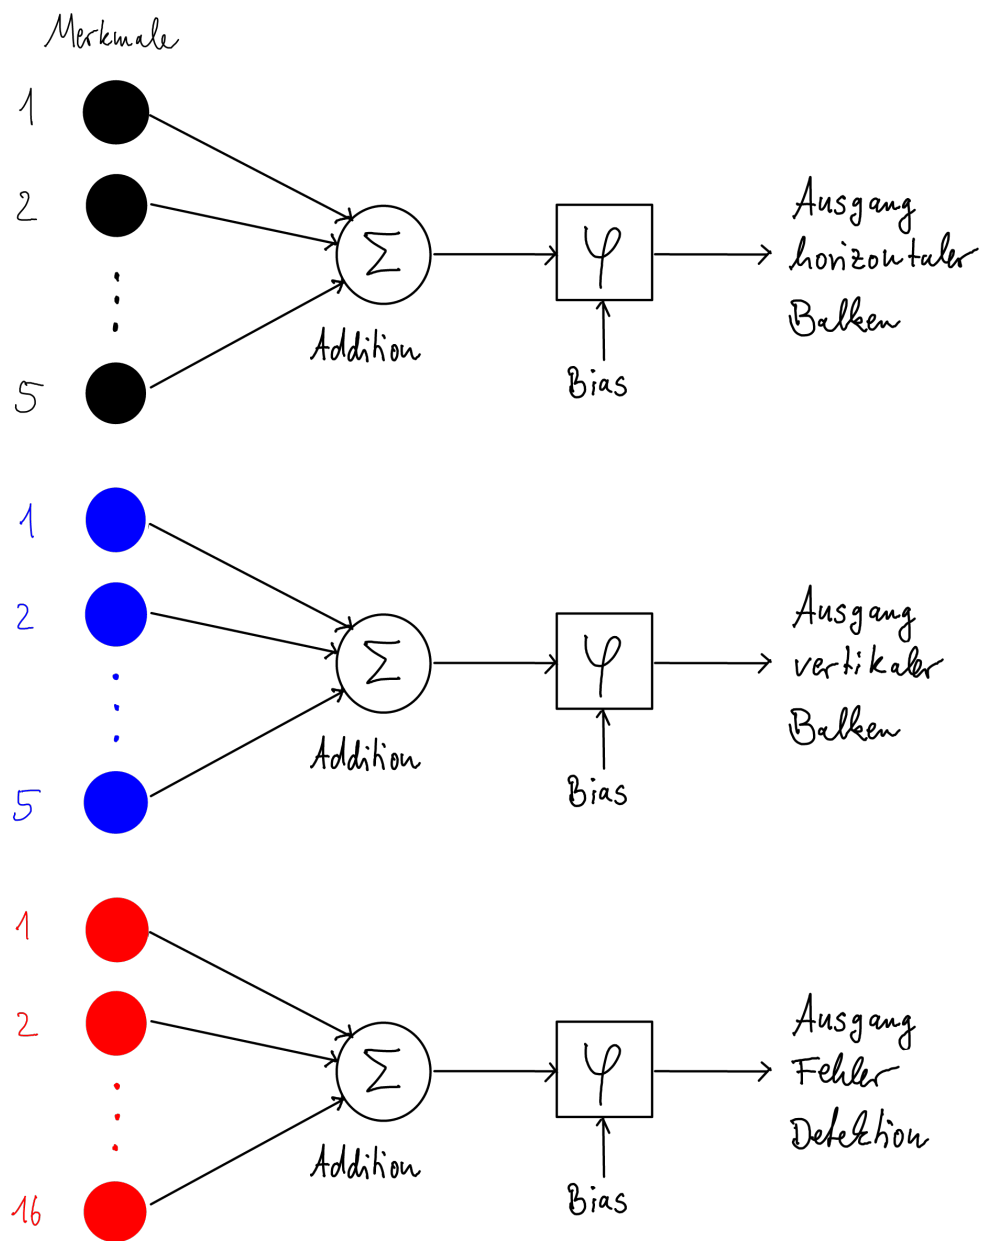


Abbildung 6: Neuronen der 2. Ebene

3 Erzeugung der Eingangsbilder

Die Erzeugung von Eingangsbildern für unser neuronales Netz, war einer der ersten Probleme, die wir gelöst haben. Testbilder zu erzeugen kann sehr Zeitaufwendig sein. Aus diesem Grund haben wir zwei Matlab-Skripte geschrieben, die uns dieses Problem abnehmen. Die beiden Dateien heißen 'GetPixelFeatureMatrix.m' und 'TestGetPixelFeatureMatrix.m'. Das 'PixelFeatureMatrix.m' erwartet als Eingang eine Merkmale-Matrix, die dann auf eine Pixel-Matrix skaliert wird. Darüber hinaus kann auch ein Rauschwert angegeben werden, um das neuronale Netz auf Rauschempfindlichkeit zu testen. Im Anschluss sind ein paar Bilder erzeugt worden mit unterschiedlichen Pixel- und Merkmalanzahlen. Bei den Kreuzdarstellungen wurde darüber hinaus die Rauscheinstellungen geändert.




Abbildung 7: 448x448, Rauschen 10

Abbildung 8: 640x640, Rauschen 10




Abbildung 9: 640x640, Rauschen 10




Abbildung 10: 585x585, Rauschen 10




Abbildung 11: 640x640, Rauschen 10




Abbildung 12: 640x640, Rauschen 10




Abbildung 13: 640x640, Rauschen 0




Abbildung 14: 640x640, Rauschen 20




Abbildung 15: 640x640, Rauschen 30




Abbildung 16: 640x640, Rauschen 40




Abbildung 17: 640x640, Rauschen 50

Abbildung 18: 640x640, Rauschen 60




Abbildung 19: 640x640, Rauschen 70

Abbildung 20: 640x640, Rauschen 80




Abbildung 21: 640x640, Rauschen 90

Abbildung 22: 640x640, Rauschen 100




Abbildung 23: 640x640, Rauschen 10

4 Gewichtsmatrizen

In diesem Abschnitt werden verschiedene Gewichtsmatrizen vorgestellt und wie wir sie erzeugt haben. Wir haben uns erst einmal auf die Erzeugung mit der Gauß-Funktion konzentriert. Es sind auch andere Funktionen möglich, wie zum Beispiel die Rayleigh-Funktion. Aus zeitlichen Gründen mussten wir darauf leider verzichten.

Zuerst soll gezeigt werden, wie die Gewichtsmatrizen grob erstellt wurden. Dafür werden im Abschnitt 4.1 3 Beispiele mit jeweils einem Slope von 75 gezeigt. Es soll außerdem verdeutlicht werden, dass es sich immer nur um einen Gauß in x- und y-Richtung handelt. Des Weiteren ist das Endergebnis immer zwischen -1 und 1. So können wir später den Ergebnisbereich besser skalieren.

In den anderen Unter-Abschnitten sind für jede Art der Gewichtsmatrizen verschiedene Slopes eingestellt.

4.1 Erzeugung der Gewichtsmatrizen

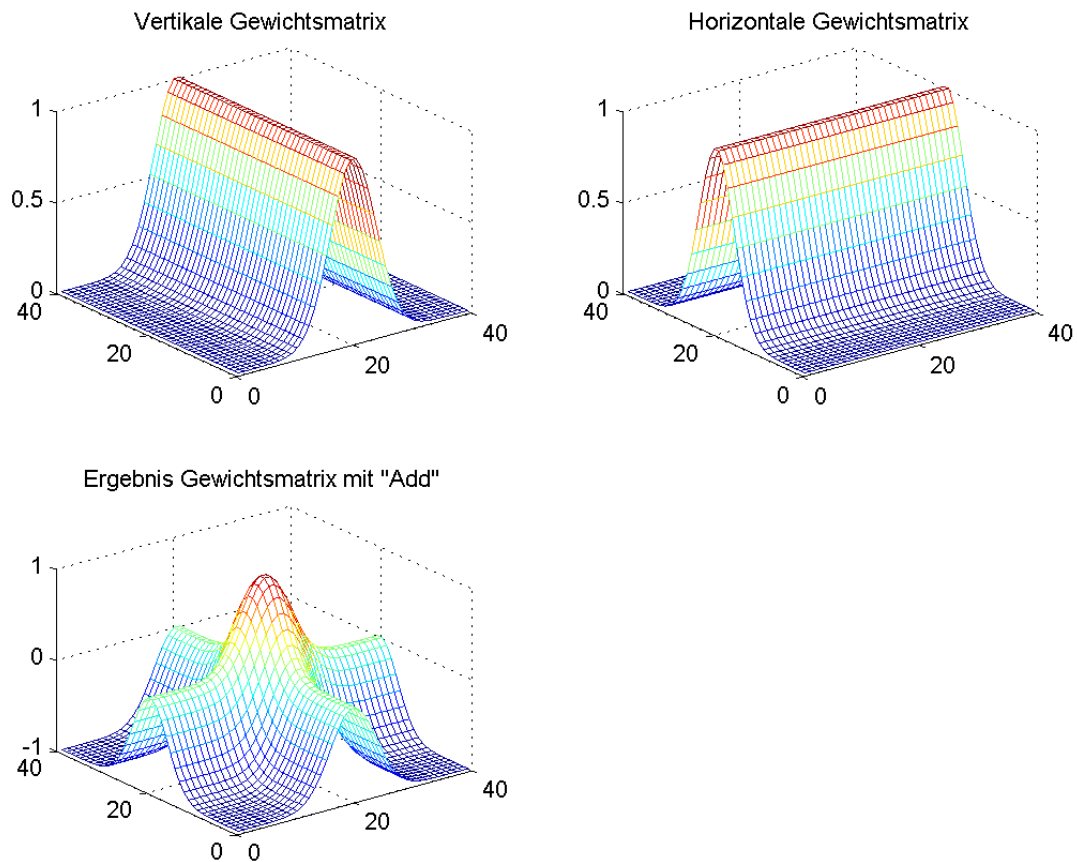


Abbildung 24: Additive Überlagerung mit Slope von 75

Listing 1: Auszug Matlab-Skript 'GetGaussWeights()'

```
elseif strcmp(type, 'Add')
    for i = 1:vN
        tempWeightMatrix(1:end, i) = (vWeightMatrix(1:end, i) + (hGauss./max(hGauss))') ./ 2;
        tempWeightMatrix(1:end, i) = tempWeightMatrix(1:end, i) .* 2 - 1;
    end
```

In Abbildung 24 wurde der 3D-Gauß in x- und y-Richtung additiv Überlagert, mit 2 multipliziert und am Ende um 1 heruntergesetzt. Siehe auch das Listing 1.

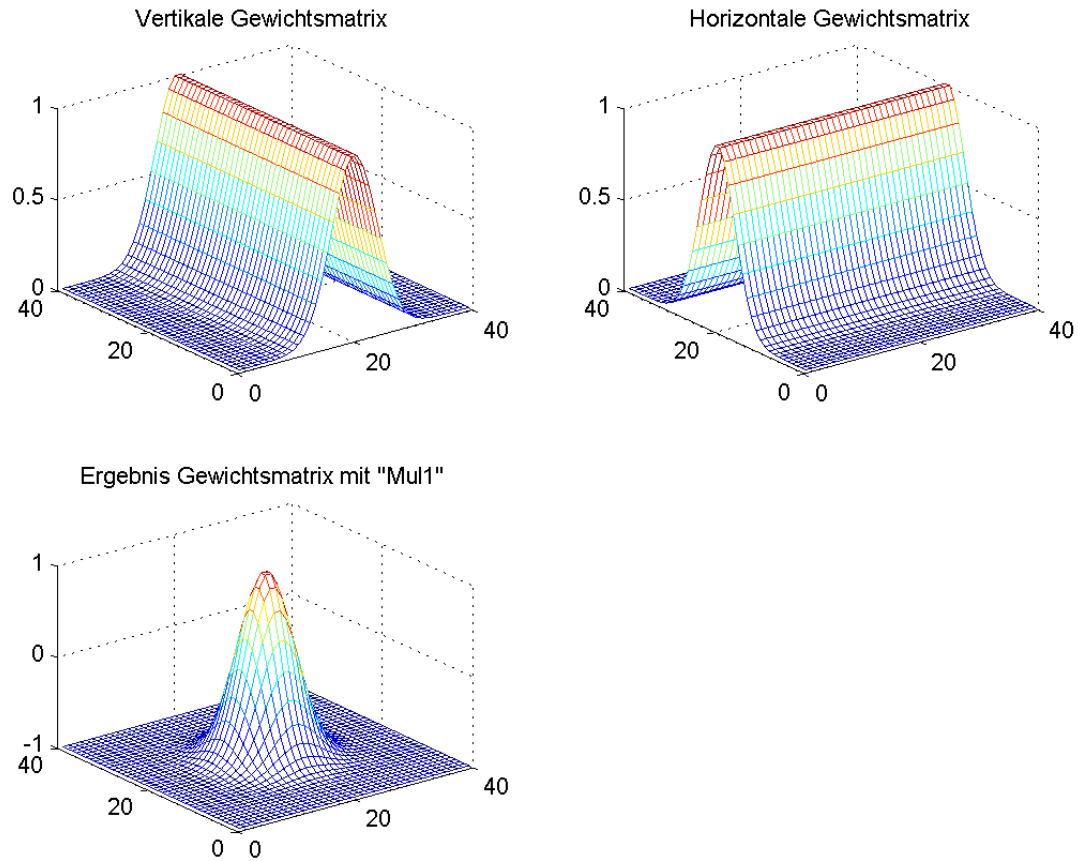


Abbildung 25: Multiplikative Überlagerung Typ 1 mit Slope von 75

Listing 2: Auszug Matlab-Skript 'GetGaussWeights()'

```

if strcmp(type, 'Mul1')
    for i = 1:vN
        tempWeightMatrix(1:end, i) = vWeightMatrix(1:end, i) .* (hGauss./max(hGauss))';
        tempWeightMatrix(1:end, i) = tempWeightMatrix(1:end, i) .* 2 - 1;
    end
end

```

In Abbildung 25 wurde der 3D-Gauß in x- und y-Richtung multiplikativ Überlagert, mit 2 multipliziert und am Ende um 1 heruntersgesetzt. Siehe auch das Listing 2.

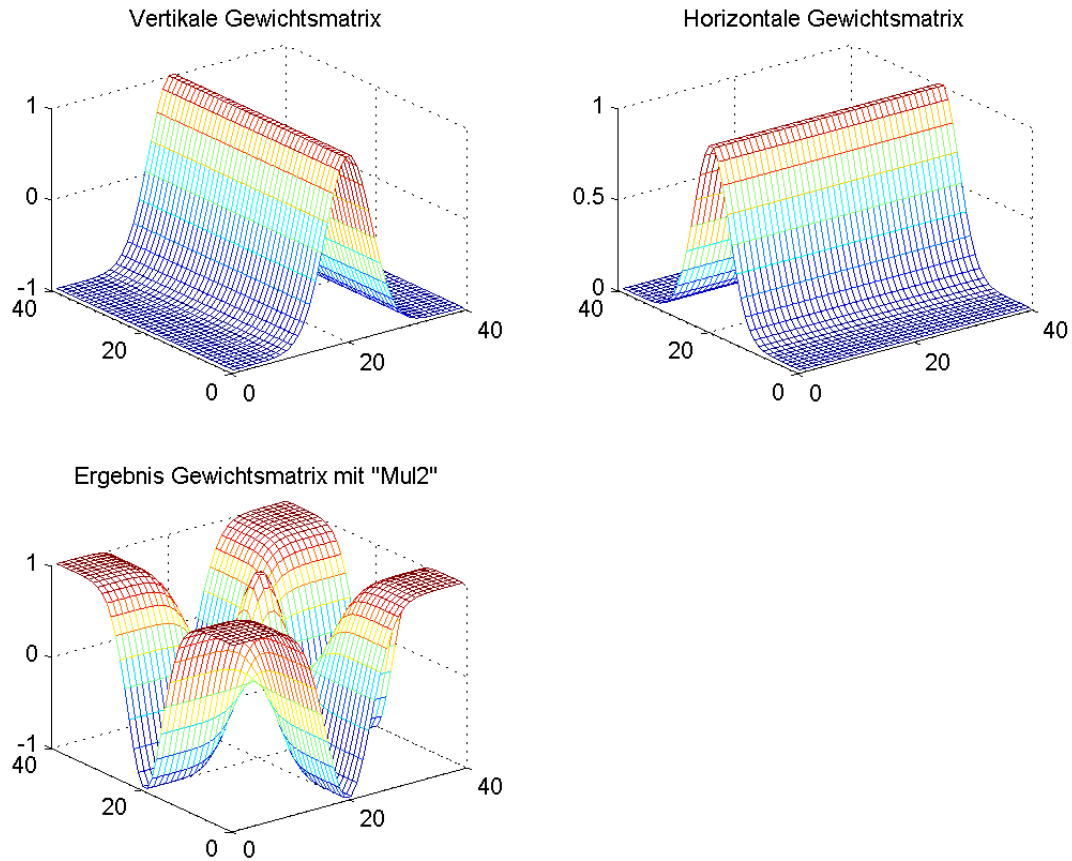


Abbildung 26: Multiplikative Überlagerung Typ 2 mit Slope von 75

Listing 3: Auszug Matlab-Skript 'GetGaussWeights()'

```
elseif strcmp(type, 'Mul2')
    for i = 1:vN
        % skalieren auf -1 bis 1
        vWeightMatrix(1:end, i) = vWeightMatrix(1:end, i) .* 2 - 1;
        % v-Gauss und h-Gauss multiplizieren
        tempWeightMatrix(1:end, i) = vWeightMatrix(1:end, i) .* ((hGauss./max(hGauss)) * 2 - 1)';
    end
```

In Abbildung 26 wurde der 3D-Gauß in der einen y-Richtung erst einmal zwischen -1 und 1 skaliert. Anschließend wird der 3D-Gauß in x-Richtung ebenfalls zwischen -1 und 1 skaliert. Am Ende werden beide multiplikativ überlagert. Siehe auch das Listing 3.

4.2 Additive Überlagerung





Abbildung 27: Additive Überlagerung mit Slo-
pe von 10

Abbildung 28: Additive Überlagerung mit Slo-
pe von 50




Abbildung 29: Additive Überlagerung mit Slope von 100

4.3 Multiplikative Überlagerung Typ 1




Abbildung 30: Multiplikative Überlagerung Typ 1 mit Slope von 10




Abbildung 31: Multiplikative Überlagerung Typ 1 mit Slope von 50

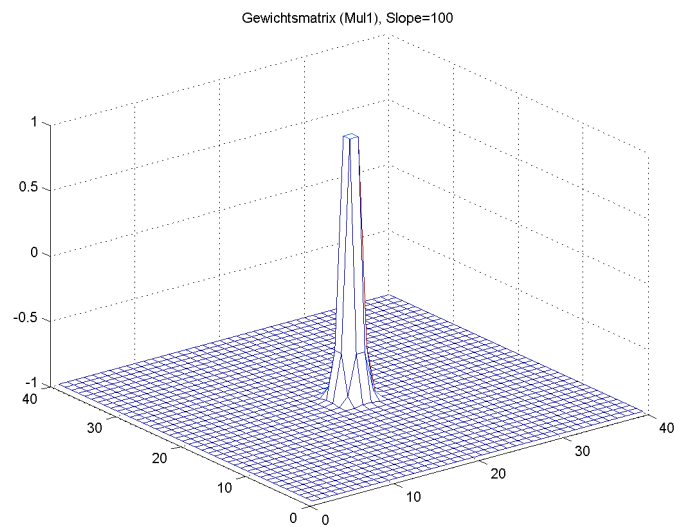


Abbildung 32: Multiplikative Überlagerung Typ 1 mit Slope von 100

4.4 Multiplikative Überlagerung Typ 2

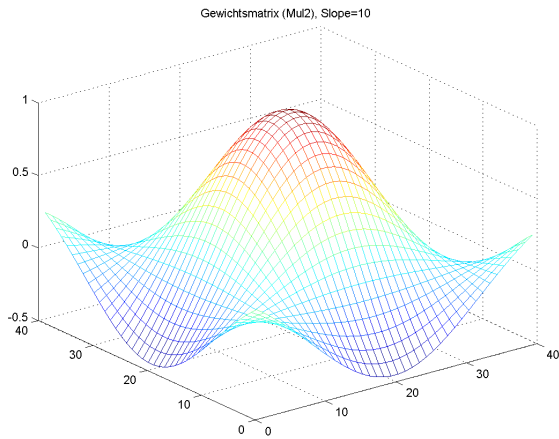


Abbildung 33: Multiplikative Überlagerung Typ 2 mit Slope von 10




Abbildung 34: Multiplikative Überlagerung Typ 2 mit Slope von 50

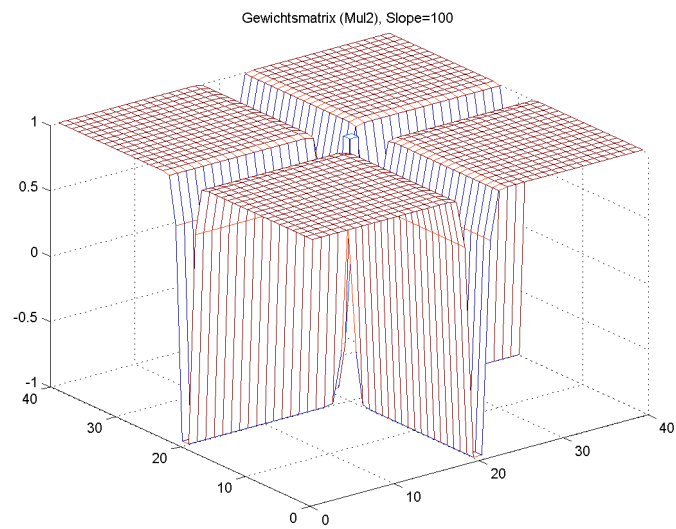


Abbildung 35: Multiplikative Überlagerung Typ 2 mit Slope von 100

4.5 Additive und Multiplikative Überlagerung


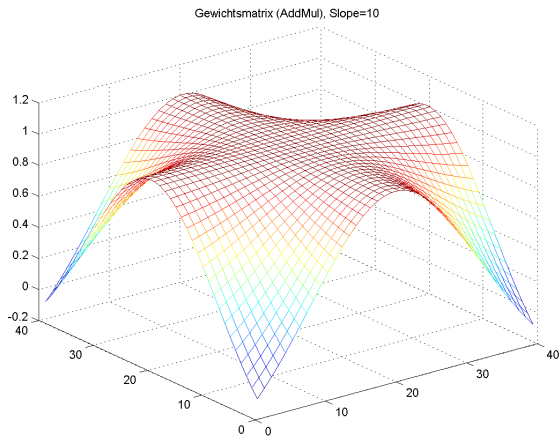


Abbildung 36: Additive und Multiplikative Überlagerung mit Slope von 10

Abbildung 37: Additive und Multiplikative Überlagerung mit Slope von 50




Abbildung 38: Additive und Multiplikative Überlagerung mit Slope von 100

4.6 Spezielle Überlagerung





Abbildung 39: Spezielle Überlagerung mit Slo-
pe von 10

Abbildung 40: Spezielle Überlagerung mit Slo-
pe von 50




Abbildung 41: Spezielle Überlagerung mit Slope von 100

Bei der Speziellen Gewichtsmatrix hat der Slope keine Auswirkungen. Das war viel mehr ein Versuch, die Auswirkung von erhöhten Gewichten in den Randbereichen zu untersuchen. Aus diesen Grund wurde sie empirisch ermittelt aus den Typen: 'Mul1', 'Mul2' und 'AddMul'.

5 Das Matlab Tool

Dieser Abschnitt soll dazu dienen, die Matlab-Skripte besser verstehen zu können. Es soll keine komplette Anleitung sein, aber die wichtigsten Zusammenhänge darstellen und Erfahrungswerte darlegen. In diesem Projekt sind viele Zeile Code in Matlab geschrieben worden. Es sollte erreicht werden, dass der Aufbau der einzelnen Dateien möglichst generisch ist. Die Entwicklung hat mithilfe von GitHub stattgefunden. Darüber können auch die Skripte und Dokumentation heruntergeladen werden.

5.1 Modulübersicht

Die Matlab-Skripte können in Kategorien eingeteilt werden. Die folgende Übersicht soll darüber Aufschluss geben.

- Ablauf und Einstellungen:

In diesen Dateien werden alle benötigten Module aufgerufen. In 'main.m' ist der komplette Ablauf hinterlegt. Für eine bessere Reproduzierbarkeit haben wir zwei weitere Dateien angelegt, in denen wir Grundeinstellungen getroffen haben für Gewichtsmatrizen, die wir in der Dokumentation auswerten.

- main.m
- SettingFileAddMul.m Einstellungen für die Gewichts-Matrix 'AddMul'.
- SettingFileSpecial.m Einstellungen für die Gewichts-Matrix 'Special'.

- Module:

In dieser Auflistung werden alle relevanten Module gezeigt, welche für die Grundfunktionen verantwortlich sind.

- GetPixelFeatureMatrix.m Diesem Modul wird eine Merkmale-Matrix übergeben und das Modul skaliert dann die Merkmale-Matrix auf eine Pixel-Matrix. Außerdem kann dem Modul ein Rauschwert zwischen 0% und 100% übergeben werden, um die Bilder mit Rauschen zu versehen. Das Modul gibt die Pixel-Matrix zurück und kann die erzeugten Bilder auch gleich als Datei speichern.

- GetNeuronOutput.m Dieses Modul ist das eigentliche Neuron. Es müssen als Parameter die Eingangszustände und Gewichte übergeben werden. Es berechnet anschließend über die Aktivierungsfunktion das Ergebnis. Es werden darüber hinaus auch Zwischenergebnisse zurückgegeben.
- GetInputFeatureMatrix.m Dieses Modul gibt vordefinierte Merkmale-Matrizen zurück, die wir häufig verwendet haben.
- GetGaussWeights.m Dieses Modul gibt eine Gewichts-Matrix zurück. Welche hinterlegt sind kann im Abschnitt 4 nachgeschaut werden.
- GetFeatureOfMatrix.m Diesem Modul kann eine Pixel-Matrix übergeben werden und gibt eine Merkmale-Matrix zurück.
- ConvMatrixToColumn.m Das Modul konvertiert eine Merkmale-Matrix in einen Spaltenvektor.

- Funktionen:

Diese Funktionen wurden von uns implementiert. Im aktuellen Stand wurde allerdings nur die Gauß- und Sigmoid-Funktion verwendet.

- GaussNormFunction.m
- SigmoidFunction.m
- LinearFunction.m
- RayleighFunction.m
- TangHFunction.m

- Hilfsfunktionen:

Die Hilfsfunktionen haben für das eigentliche Tool keine oder kaum Bedeutung. Sie werden nur genutzt, um Module zu testen oder Ausgaben zu generieren.

- TestTangHFunction.m
- TestSigmoidFunction.m
- TestRayleighFunction.m
- TestLinearFunction.m
- TestGetPixelFeatureMatrix.m

- TestGetGaussWeights.m
- TestGetFeatureOfMatrix.m
- TestGaussNormFunction.m
- SummaryWeights.m
- SummaryFunctions.m
- savePic.m

5.2 Erläuterung der Parameter

In dem Matlab-Skript 'main.n' und die abgeleiteten Skripte 'SettingFileAddMul' und 'SettingFileSpecial' sind viele Parameter enthalten, die eingestellt werden können. Dieser Abschnitt soll einen Überblick geben, was die einzelnen Parameter bewirken.

Zeile	Parameter	Erläuterung
5	pixelCnt	Pixel Anzahl in x- und y-Richtung
6	featureCnt	Merkmal Anzahl in x- und y-Richtung
7	weightType	Typ der Gewichts-Matrix (AddMul, Special, Add, Mul1, Mul2)
8	inFeatureType	voreingestellten Merkmale-Matrizen (Cross, H_Line, V_Line)
9	noise	Verrauschungsgrad zwischen 0% und 100%
10	slope	Steigung der Aktivierungs-Funktion
13	bias	Verschiebung der Aktivierungsfunktion (negativ nach rechts)
14	threshold	Auswertungsschwelle des Ergebnisses
15	domainOfDefinition	Gültigkeitsbereich der Neuronenfunktion (+/-)
18	lowerBound	Untere Grenze der Gewichts-Matrix
19	upperBound	Obere Grenze der Gewichts-Matrix
125	domainOfDefinition	2. Neuronen Ebene, h-Balken
126	bias	2. Neuronen Ebene, h-Balken
127	threshold	2. Neuronen Ebene, h-Balken
151	domainOfDefinition	2. Neuronen Ebene, v-Balken
152	bias	2. Neuronen Ebene, v-Balken
153	threshold	2. Neuronen Ebene, v-Balken
177	domainOfDefinition	2. Neuronen Ebene, Fehler Detektion
178	bias	2. Neuronen Ebene, Fehler Detektion
179	threshold	2. Neuronen Ebene, Fehler Detektion

Tabelle 1: Übersicht der Parameter

6 Auswertung

Für die Auswertung haben wir zwei von den vorgestellten Gewichtsmatrizen untersucht. Wir haben uns für die Gewichtsmatrizen 'AddMul' und 'Special' entschieden. Um reproduzierbare Ergebnisse liefern zu können, haben wir aus der 'main.m' zwei Dateien abgeleitet in denen die Konfigurationen der nachfolgenden Bilder hinterlegt sind. Die beiden Dateien heißen 'SettingFileAddMul.m' und 'SettingFileSpecial.m'. Beide Systeme wurde empirisch eingestellt und es wurde versucht ab 50% Rauschen keine vernünftigen Ergebnisse mehr zu liefern. Außerdem wurden die Bias-Werte und Threshold-Werte voreingestellt.

Als nächstes soll für ein Beispiel besprochen werden, wie die Grafiken zu lesen sind. Dafür benutzen wir die Abbildungen 42 und 43 heran. Untersucht wurde die AddMul-Gewichtsmatrix mit horizontalen Balken. Der Rauschwert ist auf 40% eingestellt. Die Farbe der eingezeichneten Punkte gibt an, ob das jeweilige Merkmal richtig detektiert wurde oder nicht. In Abbildung 42 sehen wir das Ergebnis der ersten Neuronen Ebene. In der Sigmoid-Grafik sind 25 grüne Punkte eingezeichnet. Es sind also alle Merkmale richtig detektiert worden. An dieser Stelle werden die addierten Werte der einzelnen Pixel auf eine Sigmoid-Funktion gegeben und grafisch ausgewertet.

In Abbildung 43 ist die zweite Neuronen-Ebene dargestellt. In jeder Grafik ist jeweils ein Punkt eingezeichnet. In der Grafik der 'h-Balken Detektion' ist ein grüner Punkt eingezeichnet, d.h. es wurde ein 'h-Balken' detektiert. In der Grafik der 'v-Balken Detektion' ist ein roter Punkt eingezeichnet, d.h. es wurde kein 'v-Balken' detektiert. Die letzte Grafik der zweiten Neuronen Ebene ist die 'Fehler Detektion'. In diesem Fall ist der Punkt grün, also wurde keinen Fehler detektiert. Die 'Fehler Detektion' soll angeben, wenn der voreingestellte Rauschwert überschritten wurde. Es ist zu beachten, dass die Werte aus der ersten Ebene nicht mit der Sigmoid-Funktion bearbeitet wurden, sondern lediglich mit einer linearen Aktivierungsfunktion mit dem Anstieg 1, d.h. die addierten Werte der Pixel pro Merkmal werden direkt weitergereicht.

6.1 AddMul Gewichtsmatrix

6.1.1 H-Balken

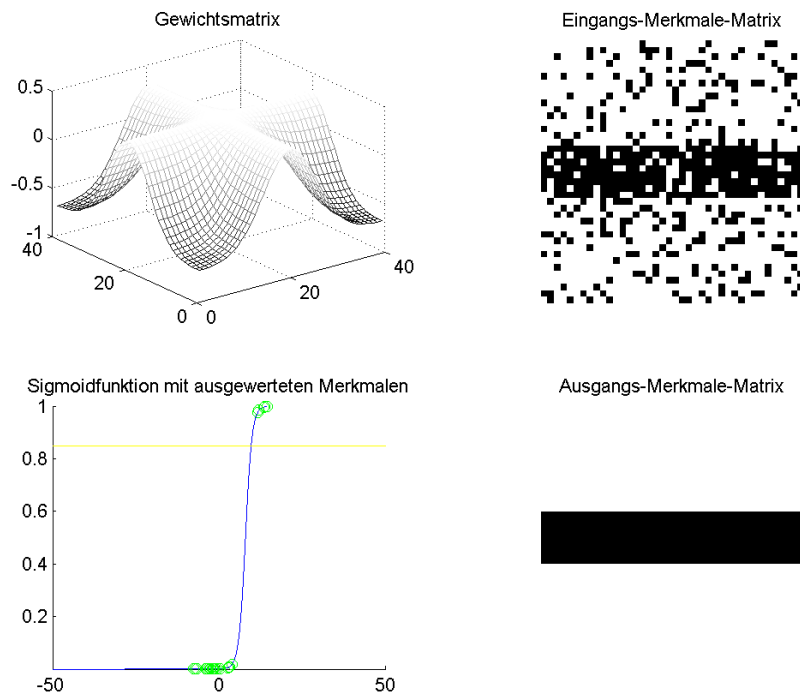


Abbildung 42: AddMul, H-Balken, 40% Rauschen, 1. Neuronen Ebene




Abbildung 43: AddMul, H-Balken, 40% Rauschen, 2. Neuronen Ebene




Abbildung 44: AddMul, H-Balken, 60% Rauschen, 1. Neuronen Ebene




Abbildung 45: AddMul, H-Balken, 60% Rauschen, 2. Neuronen Ebene

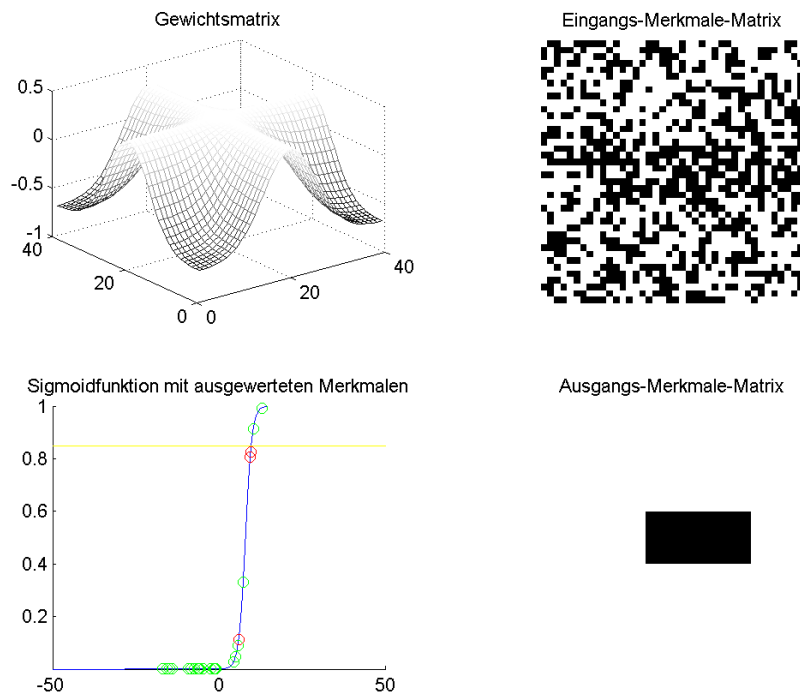


Abbildung 46: AddMul, H-Balken, 80% Rauschen, 1. Neuronen Ebene




Abbildung 47: AddMul, H-Balken, 80% Rauschen, 2. Neuronen Ebene

6.1.2 V-Balken

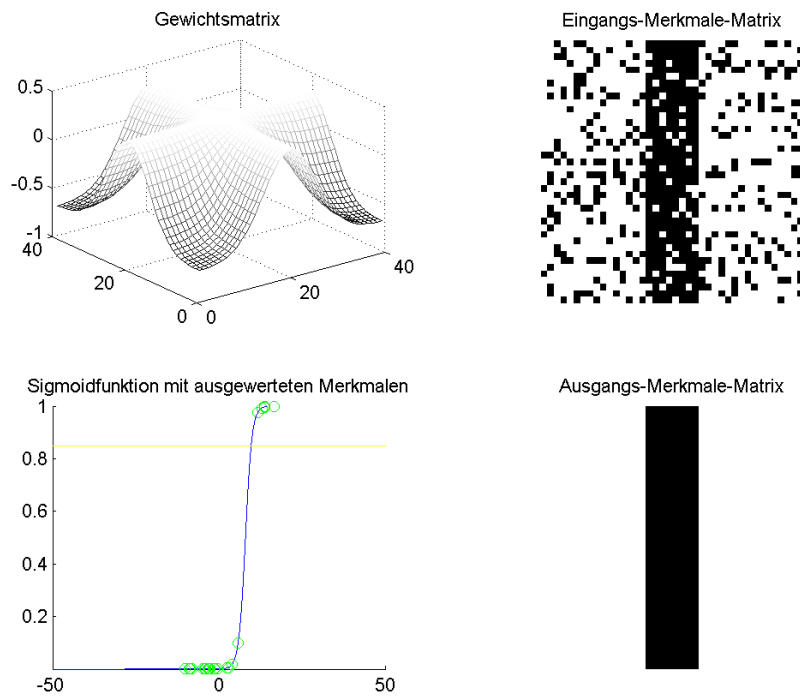


Abbildung 48: AddMul, V-Balken, 40% Rauschen, 1. Neuronen Ebene




Abbildung 49: AddMul, V-Balken, 40% Rauschen, 2. Neuronen Ebene

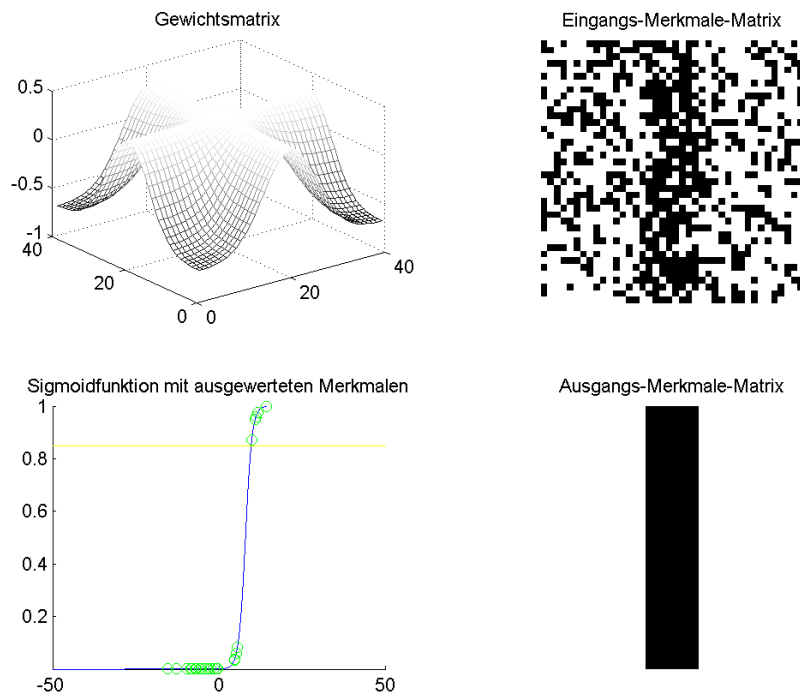


Abbildung 50: AddMul, V-Balken, 60% Rauschen, 1. Neuronen Ebene




Abbildung 51: AddMul, V-Balken, 60% Rauschen, 2. Neuronen Ebene

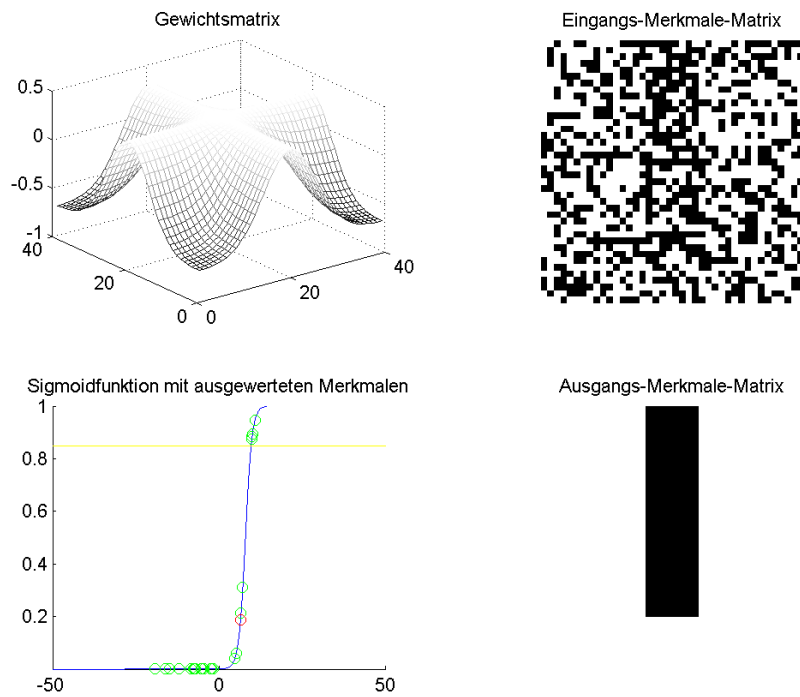


Abbildung 52: AddMul, V-Balken, 80% Rauschen, 1. Neuronen Ebene




Abbildung 53: AddMul, V-Balken, 80% Rauschen, 2. Neuronen Ebene

6.1.3 Kreuz




Abbildung 54: AddMul, Kreuz, 40% Rauschen, 1. Neuronen Ebene




Abbildung 55: AddMul, Kreuz, 40% Rauschen, 2. Neuronen Ebene

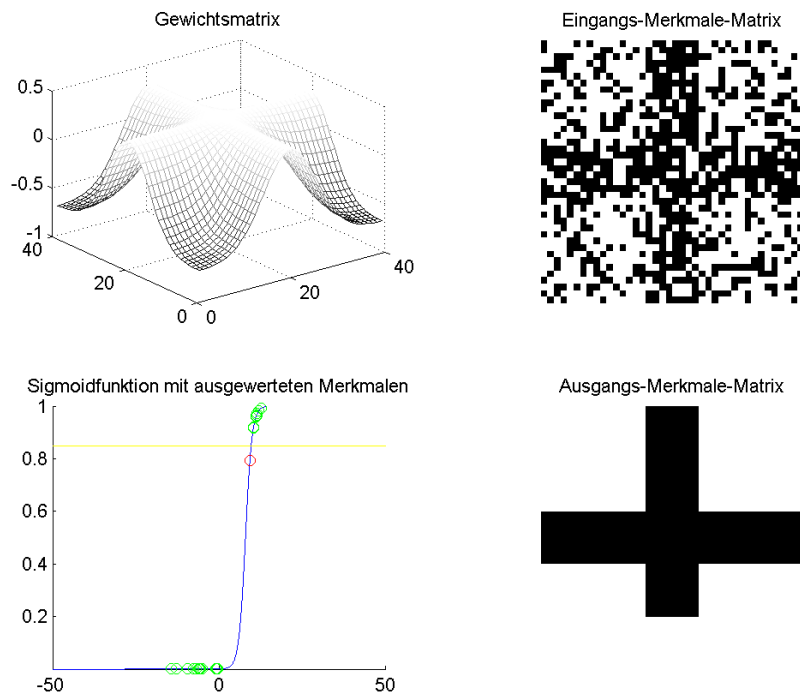


Abbildung 56: AddMul, Kreuz, 60% Rauschen, 1. Neuronen Ebene




Abbildung 57: AddMul, Kreuz, 60% Rauschen, 2. Neuronen Ebene

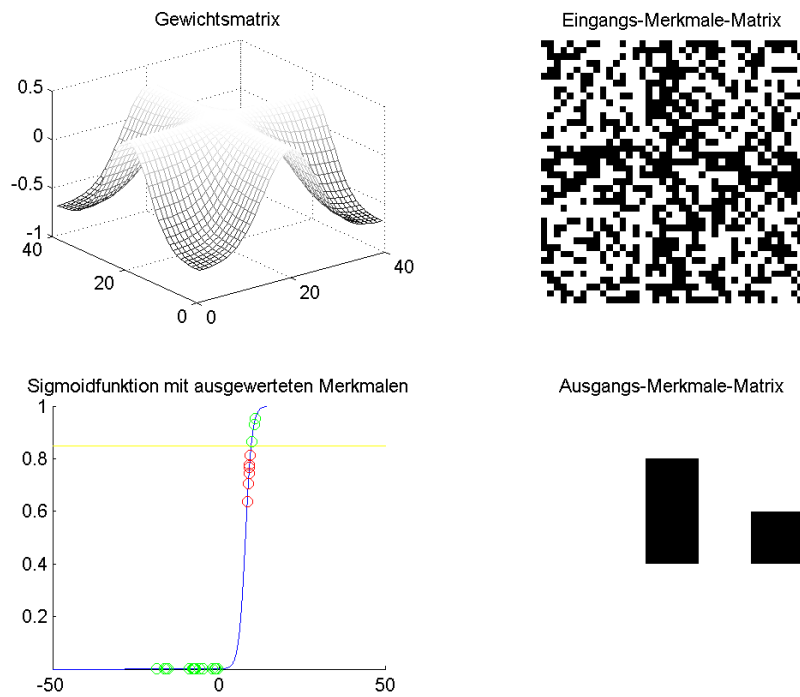


Abbildung 58: AddMul, Kreuz, 80% Rauschen, 1. Neuronen Ebene




Abbildung 59: AddMul, Kreuz, 80% Rauschen, 2. Neuronen Ebene

6.2 Special Gewichtsmatrix

6.2.1 H-Balken




Abbildung 60: Special, H-Balken, 40% Rauschen, 1. Neuronen Ebene




Abbildung 61: Special, H-Balken, 40% Rauschen, 2. Neuronen Ebene




Abbildung 62: Special, H-Balken, 60% Rauschen, 1. Neuronen Ebene




Abbildung 63: Special, H-Balken, 60% Rauschen, 2. Neuronen Ebene

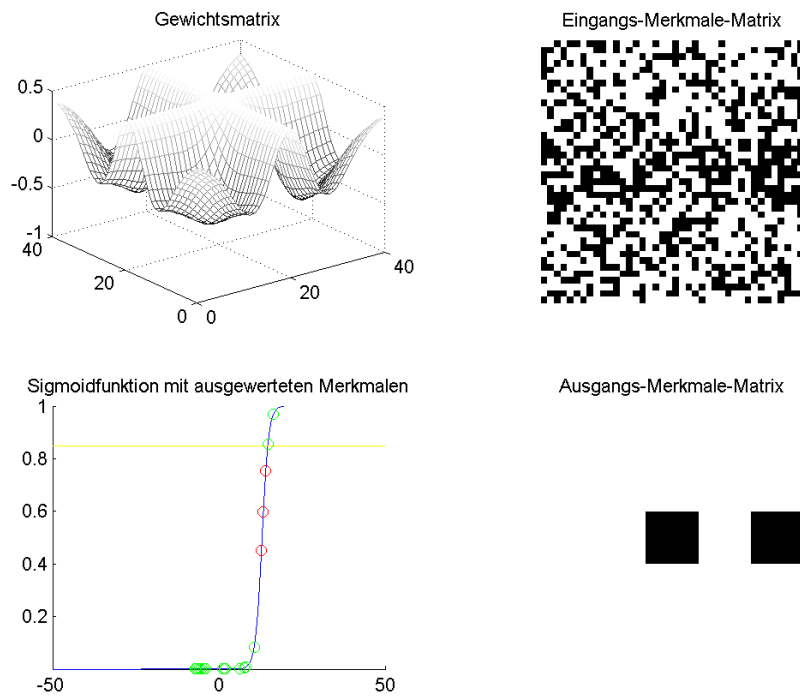


Abbildung 64: Special, H-Balken, 80% Rauschen, 1. Neuronen Ebene

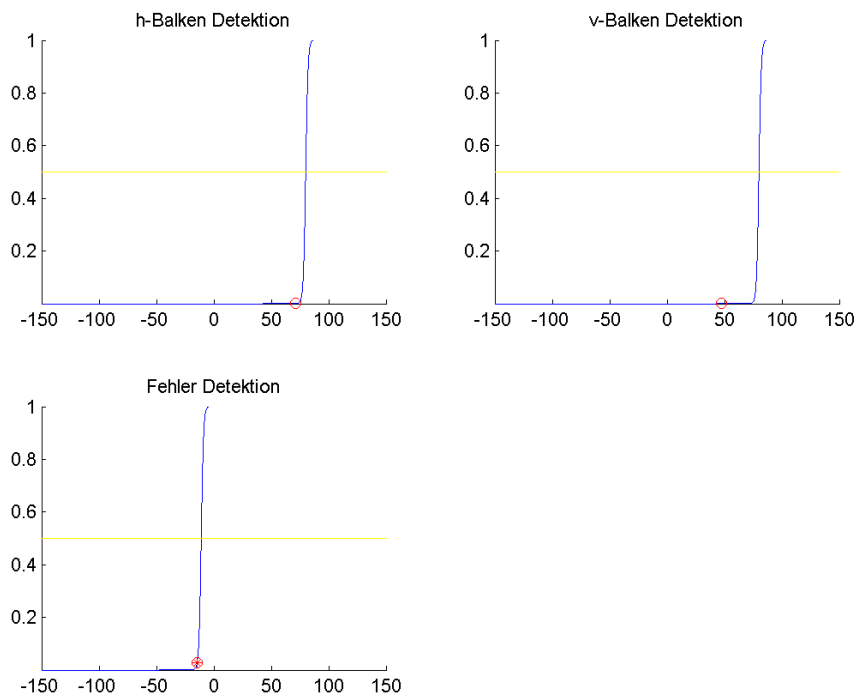


Abbildung 65: Special, H-Balken, 80% Rauschen, 2. Neuronen Ebene

6.2.2 V-Balken




Abbildung 66: Special, V-Balken, 40% Rauschen, 1. Neuronen Ebene




Abbildung 67: Special, V-Balken, 40% Rauschen, 2. Neuronen Ebene

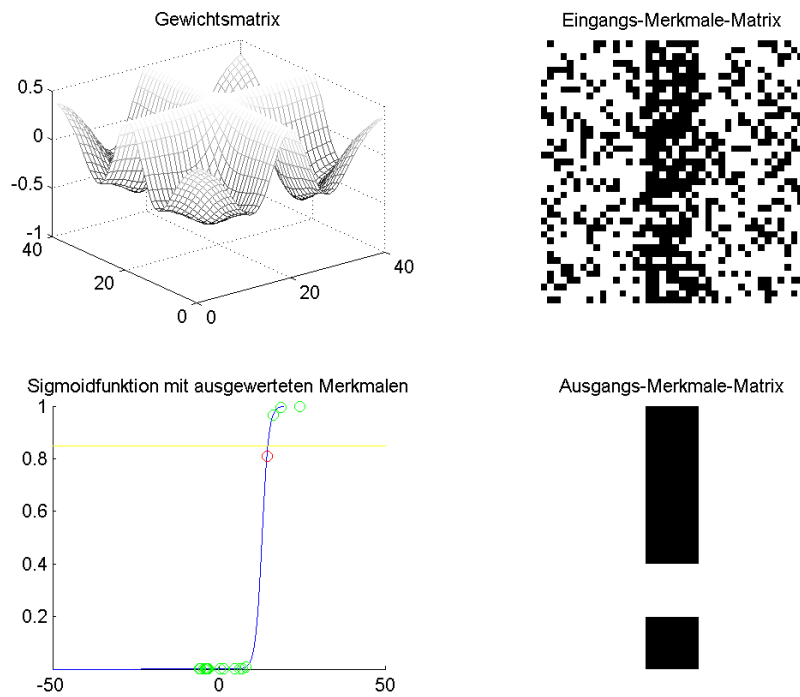


Abbildung 68: Special, V-Balken, 60% Rauschen, 1. Neuronen Ebene

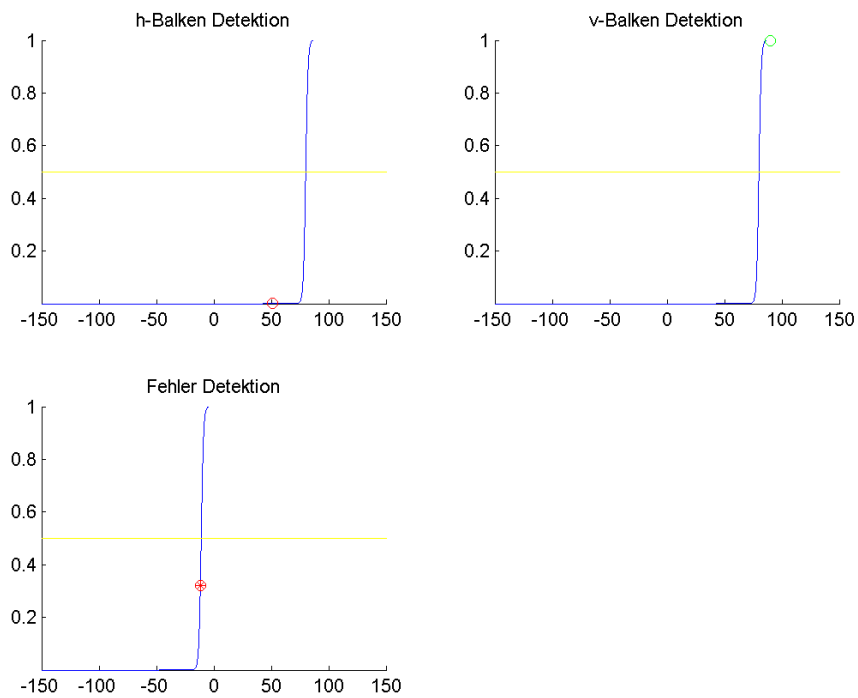


Abbildung 69: Special, V-Balken, 60% Rauschen, 2. Neuronen Ebene

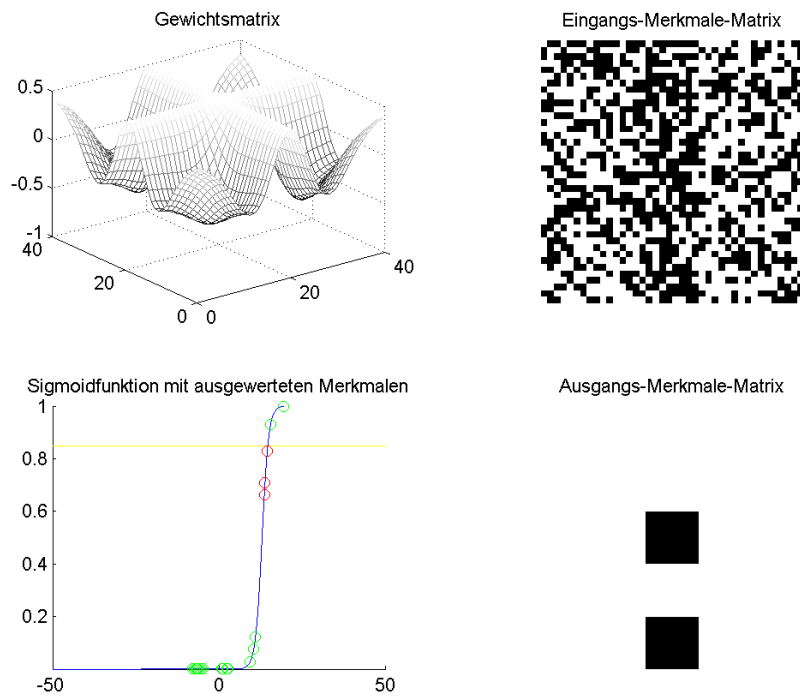


Abbildung 70: Special, V-Balken, 80% Rauschen, 1. Neuronen Ebene




Abbildung 71: Special, V-Balken, 80% Rauschen, 2. Neuronen Ebene

6.2.3 Kreuz




Abbildung 72: Special, Kreuz, 40% Rauschen, 1. Neuronen Ebene




Abbildung 73: Special, Kreuz, 40% Rauschen, 2. Neuronen Ebene




Abbildung 74: Special, Kreuz, 60% Rauschen, 1. Neuronen Ebene




Abbildung 75: Special, Kreuz, 60% Rauschen, 2. Neuronen Ebene

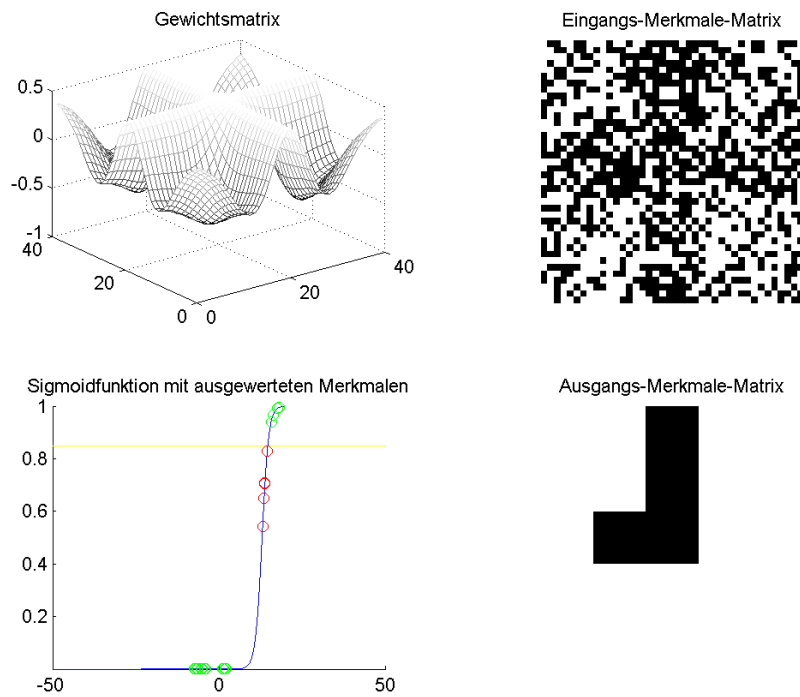


Abbildung 76: Special, Kreuz, 80% Rauschen, 1. Neuronen Ebene

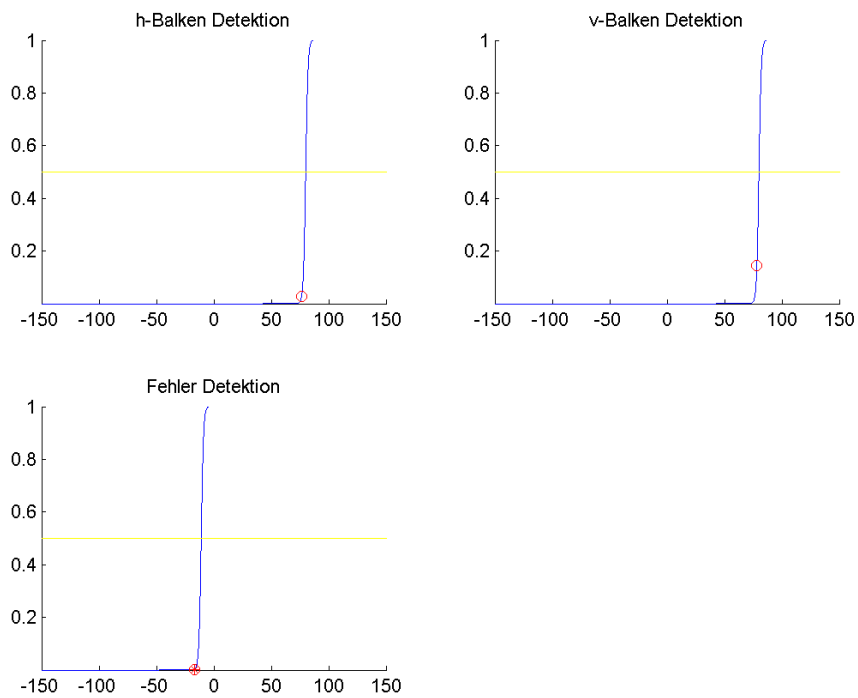


Abbildung 77: Special, Kreuz, 80% Rauschen, 2. Neuronen Ebene

7 Fazit

In diesem Projekt haben wir ein neuronales Netz zur Detektion von horizontalen und vertikalen Balken entwickelt. Das neuronale Netz besteht dabei aus zwei Neuronen Schichten. Die Anzahl der benötigten Neuronen hängt dabei von der Anzahl der Merkmale ab. Die Anzahl der Neuronen wächst Linear mit der Anzahl der Merkmalen. Die erste Neuronen Ebene fasst dabei alle Pixel zu den jeweiligen Merkmalen zusammen. Jedes Pixel wird dabei über die Gewichts-Matrix bewertet. In der zweiten Neuronen Ebene findet eine Verfeinerung des Ergebnisses statt. Erst die zweite Neuronen Ebene wertet die Informationen aus den Merkmalen aus.

Entwickelt haben wir verschiedene Möglichkeiten von Gewichts-Matrizen. Untersucht haben wir am Ende die zwei erfolgversprechendsten Gewichts-Matrizen 'AddMul' und 'Special'. 'AddMul' hatte dabei die maximale Möglichkeit Parameter einzustellen. Dies ist bei der Special-Gewichtsmatrix nicht möglich. Vergleicht man beide Typen von Gewichts-Matrizen fällt kaum ein Unterschied im Ergebnis auf. Aus diesem Grund ist für uns die AddMul-Gewichts-Matrix besser geeignet, weil sie einfacher aufgebaut und besser einstellbar ist. Bei der Special-Gewichts-Matrix konnte sich ein Vorteil der erhöhten Randbereiche nicht bestätigen. Durch die Erhöhung haben sich lediglich die Schwellen der Detektion verändert.

Um die richtige Konfiguration der verschiedenen Parameter zu finden, haben wir länger gebraucht als erwartet. Es hat sich teilweise als sehr schwierig erwiesen vernünftige Werte zu finden. Die Ergebnisse hängen sehr stark davon ab, wie viel Rauschen man in den Bildern hat. Erste Einstellungen des neuronalen Netzes haben in komplett verrauschten Bildern ein Kreuz detektiert. Durch sukzessive Anpassung der Schwellen haben wir diesen Problem in den Griff bekommen.




Abbildung 78: Merkmale-Gruppen

Ein weiteres Problem war es, die Merkmale der ersten Neuronen Ebene in zwei Gruppen zu unterteilen und damit separierbar zu machen. Jede Gruppe soll dabei möglichst zusammen-

hängend sein. Für das bessere Verständnis siehe Abbildung 78. In diesem Fall muss die Flanke der Sigmoid-Funktion zwischen den beiden Gruppen liegen. Die Verschiebung der Sigmoid-Funktion wird über den jeweiligen Bias-Parameter erreicht. Mit dem Threshold-Parameter wird die Schwelle festgelegt, ab wann ein aktives Merkmal detektiert werden soll. Werden die Parameter 'pixelCnt', 'featureCnt', 'lowerBound', 'upperBound' oder 'slope' geändert, dann müssen auch die Parameter 'bias', 'threshold' und 'domainOfDefinition' neu eingestellt werden.

Im Gegensatz zur ersten Ebene sind die richtigen Einstellungen für die zweite Ebene deutlich leichter zu finden, weil mal statt einer Sigmoid-Funktion drei Sigmoid-Funktionen zum Einstellen hat. Zur Erinnerung die zweite Neuronen Ebene erhält von der ersten Neuronen Ebene nicht die Werte der Sigmoid-Funktion, sondern die addierten Pixel-Gewichte ohne weitere Verarbeitung. Bei der zweiten Ebene können die Einstellungen für die Detektion des 'H-Balken', 'V-Balken' und des 'Fehlers' unabhängig voneinander eingestellt werden.

Mit dieser Arbeit haben wir einen Meilenstein gelegt, um ein Neuronales Netz in Hardware zu implementieren. Wir haben Erfahrungen gesammelt, wie ein selbst lernendes neuronales Netz die Gewichte findet und wie es aufgebaut sein muss, um vernünftige Ergebnisse zu liefern. Im Weiteren werden wir uns damit befassen unsere Ergebnisse in Hardware zu implementieren.

Literatur

- [1] Anna Corves. [www.dasgehirn.info](https://www.dasgehirn.info/grundlagen/kommunikation-der-zellen/nervenzellen-im-gespraech), 2012. <https://www.dasgehirn.info/grundlagen/kommunikation-der-zellen/nervenzellen-im-gespraech>, Letzter Zugriff 21. Oktober 2017.
- [2] Klaus Peter Kratzer. Neuronale Netze. Hanser, 1991.
- [3] Alessandro Mazzetti. Praktische Einführung in Neuronale Netze. Heise, 1996.
- [4] Andrea Schäfers. www.gehirnlernen.de. <https://www.gehirnlernen.de/gehirn/die-einzelne-nervenzelle-und-wie-sie-mit-anderen-kommuniziert/>, Letzter Zugriff 21. Oktober 2017.